

CS3611

计算机网络大作业

2026 Spring

题目五：基于 UDP 的应用层可靠传输与 AI 驱动拥塞控制协议实现

第 XX 组（成员姓名与学号待最终核对）

小组成员

序号	姓名 / GitHub 账号	学号
1	蒋昊翔 / Lawrenclia	524030910083
2	dumeili114514	待补
3	gggggs1	待补
4	liujin / hero-always	待补

2026 年 6 月 14 日

1 项目概述

1.1 实验目标

本项目模拟 QUIC 将可靠传输和拥塞控制上移到应用层的思想, 基于 Python 原生 UDP Socket 实现带有确认、重传、滑动窗口和拥塞窗口控制的可靠传输协议。在此基础上, 项目构建虚拟瓶颈链路, 对比传统 AIMD 与 Q-Learning、DQN 两类智能拥塞控制策略在吞吐、时延和重传方面的表现。

1.2 完成情况总览

表 1: 功能完成情况

类别	功能点	状态
基础功能	UDP Payload 中封装 Sequence Number、Timestamp 与 1024 字节 Payload	✓
	接收端累计 ACK、发送端未确认队列、RTO 定时重传与 SRTT 采样	✓
	虚拟瓶颈链路: 固定服务速率、有限队列、排队延迟与队列溢出丢包	✓
	AIMD 拥塞控制基线: ACK 加性增、超时或快速重传时乘性减	✓
	Q-Learning 控制器: 6 状态、3 动作、在线 Q-Table 更新、JSON 状态阈值与可视化	✓
扩展功能	带宽中途减半, 观察控制器对动态网络突变的响应	✓
	连续 3 个重复 ACK 触发快速重传, 接收端缓存乱序分组	✓
	DQN 深度强化学习控制器, 使用 PyTorch 模型输出 CWND 调整动作	✓
未选择项	学生自定义开放性问题: 本组未选择该可选扩展, 本文不计入完成范围	未选

1.3 需求覆盖与提交物清单

除自定义开放性问题外, 题目五基础功能和已选扩展均已完成。代码、实验数据和文档提交物对应关系如下。

表 2: 题目要求与仓库文件对应关系

要求项	实现与证据	提交物
应用层可靠传输	<code>protocol.py</code> 定义 <code>SEQ+Timestamp+Payload</code> 与 <code>ACK</code> ; <code>sender.py</code> 维护 <code>unacked</code> 、 <code>ACK worker</code> 、 <code>timer worker</code> 、 <code>RTO</code> 重传、 <code>RTT/SRTT</code> ; <code>receiver.py</code> 返回累计 <code>ACK</code>	<code>protocol.py</code> , <code>sender.py</code> , <code>receiver.py</code>
虚拟瓶颈链路	<code>VirtualFunnellink</code> 在 <code>sendto()</code> 外层实现有限 <code>FIFO</code> 队列、固定服务间隔、队列满丢弃和链路统计	<code>virtual_link.py</code>
AIMD 与 Q-Learning	<code>sender.py</code> 中 <code>CongestionController</code> 支持 <code>fixed/aimd/qlearning</code> ; Q-Learning 使用 6 状态、3 动作、 ϵ -greedy 和 Bellman 更新	<code>q_table.json</code> , <code>train_q_learning.py</code> , <code>screen_q_learning.py</code>
数据记录与可视化	<code>Sender</code> 输出 <code>artifacts/metrics/metrics.csv</code> 与 <code>artifacts/metrics/history.csv</code> ; <code>plot_metrics.py</code> 生成 <code>CWND</code> 、吞吐和 <code>RTT</code> 对比图; 报告包含 Q-Learning 多轮趋势图	<code>artifacts/metrics/</code> , <code>plot_metrics.py</code> , <code>report/figures/*.png</code>
动态突变、快重传、DQN	<code>--link-bandwidth-drop-after-packets</code> 模拟中途带宽减半; 3 个重复 <code>ACK</code> 触发 <code>FAST</code> 重传; DQN 用连续网络状态和 PyTorch 网络输出 <code>CWND</code> 调整动作	<code>dqn_model.pt</code> , <code>train_dqn.py</code> , <code>artifacts/demo_results/</code>
演示与文档	一键演示依次运行 AIMD、Q-Learning、DQN 和带宽突变场景, 保存日志、CSV 和图表; 本报告与 poster 使用同一批结果	<code>Run_Demo.command</code> , <code>demo_runner.py</code> , <code>report/output/</code>

1.4 模块与分工

分工依据本地 Git 提交记录、分支和 GitHub PR 记录整理。PR #1 (`finish project5`) 合并了可靠传输、虚拟链路、AIMD/Q-Learning、CSV 记录与可视化主线; PR #2 (`Add DQN-based congestion control and training script`) 合并了 DQN 扩展。自动化 review / conflict-fix 机器人只作为辅助工具, 不计入小组成员贡献。

表 3: GitHub commit 级别分工明细

成员 / 账号	主要证据	具体工作	产出
Lawrenclia / Haoxiang Jiang	6a688ac, 1ac1838, efe154b, 06282cd, 124c984, PR #1 管理	初始化仓库与 README; 建立可靠传输底层, 补齐 SEQ/Timestamp/Payload 封装、发送端未确认队列、ACK 接收线程、RTO timer、RTT/SRTT 采样; 实现/整合快速重传和乱序处理说明; 重构实验脚本, 修复 Q-Table、metrics、history 输出目录问题; 整合报告、poster 和一键演示。	protocol.py; sender.py; receiver.py; README; demo/report/poster
dumeili114514	92d880d, dc95a4e	设计早期 Q-Learning 智能拥塞控制核心: 6 个 RTT 趋势/丢包离散状态、保持/加一/减半 3 个动作、奖励函数、 ϵ -greedy 探索与 Bellman 更新; 编写多轮 Q-Learning 训练脚本; 补入 AIMD 基线, 在 ACK 时加性增、拥塞信号时乘性减, 并配合 benchmark/绘图验证。	congestion_control.py; train_q_learning.py; Q-Learning/AIMD 逻辑
ggggs1	228a9ae, e790d8d, PR #1 分支	实现虚拟网络拓扑模拟: VirtualFunnellink 有限 FIFO 队列、固定服务间隔、队列溢出丢包、链路统计和日志; 将虚拟链路参数接入 Sender; 完成题目五收尾文档, 添加 plot_metrics.py 以及 AIMD/Q-Learning 对比图, 支撑报告中的实验数据与可视化。	virtual_link.py; plot_metrics.py; required comparison 图; 实验提交文档
liujin / hero-always	b7cf010, PR #2	完成 DQN 扩展: 在 sender.py 增加 dqn 模式、由 RTT、RTT 趋势、loss%、timeout%、CWND 和 ACK 利用率组成的连续状态、状态归一化、动作乘数 (0.70, 0.90, 1.00, 1.10, 1.25)、单周期增窗上限、经验回放、SmoothL1 loss、target network、模型加载/保存和 DQN 日志; 编写 train_dqn.py 多轮训练脚本, 提交模型权重与 DQN 对比实验图。	train_dqn.py; dqn_model.pt; DQN comparison 图; artifacts/training/

2 系统设计

2.1 整体架构

系统由 Sender、Receiver、应用层协议封装、虚拟瓶颈链路、拥塞控制器和数据记录流水线组成。Sender 产生固定大小分组并按当前 CWND 控制在途包数量; VirtualFunnellink 在真实 sendto() 之前模拟固定带宽和有限缓存; Receiver 维护期望序号并返回累计 ACK; Sender 根据 ACK 采样 RTT、推进窗口并触发智能控制器。

UDP Reliable Transport with AI Congestion Control

Application-layer reliability, virtual bottleneck link, AIMD/Q-Learning/DQN adaptive CWND




图 1: 系统架构与数据反馈路径

2.2 应用层 UDP 协议

表 4: 自定义数据包与 ACK 格式

字段	长度	说明
Sequence Number	4 Bytes	无符号整数，标识分组序号
Timestamp	8 Bytes	发送端写入 Unix 时间戳，用于 RTT 采样
Payload	1024 Bytes	固定长度数据负载
ACK Number	4 Bytes	接收端返回的最大连续确认序号，-1 表示尚无连续分组

协议由 `protocol.py` 实现，核心格式为 `"!Id"` 与 `"!i"`。其中 `!` 表示网络字节序，`I` 为 4 字节无符号整数，`d` 为 8 字节浮点时间戳。每次新发或重传都会重新封包，以保证 `Timestamp` 反映本次上链路的时间。

2.3 可靠传输与虚拟链路

发送端用 `unacked` 字典保存未确认分组的 `Payload`、最近发送时刻、写入报文的时间戳和发送次数。主线程只在 `len(unacked) < cwnd` 时发送新分组；ACK 线程收到累计 ACK 后删除所有 `seq <= ack_number` 的记录，并根据被确认分组的 `Timestamp` 计算 `RTT` 与 `SRTT`；Timer 线程周期扫描 `unacked`，超过 `RTO` 即重传。

虚拟瓶颈链路包装 Sender 的发送动作。应用层数据先进入容量有限的 `FIFO` 队列，再由后台线程按固定服务间隔发往真实 `UDP Socket`。若队列已满，虚拟链路直接丢弃新分组并记录丢包日志；若启用带宽突变参数，链路会在转发指定包数后调大服务间隔，模拟带宽突然下降。

3 核心实现

3.1 AIMD 基线

AIMD 模式复现 TCP Reno 的拥塞避免思想。初始化 $CWND = 1$ ；每收到新 ACK，执行

$$CWND \leftarrow \min(CWND_{\max}, CWND + \frac{newly_acked}{CWND})$$

当 RTO 或快速重传表示出现拥塞信号时，执行

$$CWND \leftarrow \max(1, CWND/2)$$

因此 AIMD 曲线应呈现“逐步上升、拥塞后骤降、再重新上升”的锯齿形态。

3.2 Q-Learning 智能拥塞控制

Q-Learning 控制器每隔固定 100ms 统计 ACK 数、平均 RTT、重传次数和 RTO timeout 次数，使用 6 个离散状态：

$$State = \{RTT_up, RTT_down, RTT_stable\} \times \{loss, no_loss\}$$

动作空间严格保持为三个动作：0 保持、1 表示 $CWND+1$ 、2 表示 $CWND/2$ ，动作执行后的窗口保持为不小于 1 的整数。最终 V9 模型在 Q-Table JSON 的 metadata 中保存 `rtt_trend_threshold_ratio=0.05`，SRTT 相对上一周期变化超过 5% 时判定为上升或下降，否则归为稳定。奖励函数为：

$$R = w_G G - w_T N_{timeout} - w_R N_{retr} - w_D \max(0, RTT_{ms} - RTT_{target})$$

其中 G 为控制周期内确认分组数， $N_{timeout}$ 为 RTO 超时次数， N_{retr} 为总重传次数。训练阶段通过该奖励函数产生候选 Q 表；正式评估使用 `--epsilon 0 --q-eval`，不探索、不在线更新。每个有效控制周期按 Bellman 公式更新 Q 值：

$$Q(s, a) \leftarrow Q(s, a) + \alpha(R + \gamma \max_{a'} Q(s', a') - Q(s, a))$$

旧实现使用动态 SRTT 作为控制周期，拥塞时周期变长会收集更多 ACK，使拥塞状态得到不公平的正奖励。当前实现改用固定 100ms 周期，使各状态奖励可比；周期内既无 ACK 也无丢包时跳过决策。控制器启动时尚未执行动作，因此上一状态和动作初始化为 `None`，第一周期只选动作，从第二周期开始更新实际执行过的状态动作对。训练后的策略保存到 `q_table.json`，评估时使用 `--epsilon 0 --q-eval`，保证不探索、不更新、不覆盖模型。

3.3 DQN 扩展

DQN 模式将离散 Q-Table 扩展为神经网络控制器。输入为 RTT、RTT 趋势、丢包率、timeout 比例、当前 CWND 和 ACK 利用率组成的连续状态，输出 5 个动作的 Q 值。动作对应 0.70、0.90、1.00、1.10 和 1.25 的 CWND 乘数。为避免随机探索过快打满队列，增窗动作每个控制周期最多增加 1 个窗口单位。模型由三层全连接网络实现，并通过经验回放和 target network 训练，权重保存为 `dqn_model.pt`。该扩展用于探索连续网络状态下更细粒度的拥塞响应。

4 测试与结果

4.1 测试环境与方法

实验使用本地环回地址 127.0.0.1，Receiver 设置 2% 随机丢包、10ms 基础延迟和 3ms 抖动，Sender 启用有限队列虚拟瓶颈链路。最终评估使用 300 个分组和 8 个随机种子，同时记录平均值与最差值；单个 case 最长运行 45 秒，超时模型记为失败，避免坏参数拖死整轮筛选。

最后一轮保持 6 个状态和 3 个动作不变，先比较 `rtt_up|no_loss` 下保持、加一和减半三种动作，再对最优的“先保持”策略搜索 3%–20% RTT 趋势阈值。`screen_q_learning.py` 将 AIMD 一并纳入，使所有模型面对相同场景、参数和随机种子。5% 候选的吞吐与稳定性综合表现最佳，因此被安装为最终 V9。

表 5: AIMD 与最终 Q-Learning V9 的 8 种子公平评估

场景	模型	平均吞吐 (Mbps)	最差吞吐 (Mbps)	平均 RTT (ms)	最差 RTT (ms)	重传	超时	平均分	最差分
正常链路	AIMD	0.563	0.540	99.14	125.00	40.62	21.00	-0.407	-1.391
正常链路	V9	0.559	0.513	40.77	50.43	9.38	4.50	0.378	0.151
带宽减半	AIMD	0.353	0.323	107.38	119.57	61.62	39.00	-1.266	-2.076
带宽减半	V9	0.385	0.357	60.84	71.59	18.62	12.00	-0.112	-0.529

4.2 结果分析

正常链路下，V9 的平均吞吐仅比 AIMD 低 0.8%，但平均 RTT 降低 58.9%，重传减少 76.9%，超时减少 78.6%。带宽减半时，V9 的平均吞吐提高 9.0%，同时 RTT 降低 43.3%，重传减少 69.8%，超时减少 69.2%。所有正式评估均完成 300/300 分组确认。

AIMD 图上的 CWND 更高，是因为它更容易把瓶颈队列持续填满；更高的在途窗口会带来更高排队 RTT 和更多重传，不能单独作为性能更好的证据。正常链路中，AIMD 的吞吐优势不足 1%，却产生约 2.4 倍 RTT 和 4.3 倍重传；在带宽骤降场景，其吞吐也低于 V9。因此本报告综合吞吐、RTT、重传、超时和跨种子分数判断。

最终策略保留三个动作。RTT 下降或稳定且无丢包时执行 $CWND+1$ ；任意状态出现丢包时执行 $CWND/2$ ；SRTT 上升超过 5% 但尚未丢包时先保持窗口。完整结果位于 `artifacts/training/` 下的 `q_opt_threshold_final/` 与 `q_opt_aimd_control/` 目录；最终模型备份为 `q_table_final_v9_best.json`。

5 操作手册

5.1 环境准备

核心可靠传输、AIMD 与 Q-Learning 只依赖 Python 标准库；训练进度条需要 `tqdm`，绘图需要 `matplotlib`，DQN 需要 `torch`。

Listing 1: 依赖安装

```
1 python3 -m pip install tqdm matplotlib torch
```

5.2 运行方式

最简方式是在 macOS 双击 `Run_Demo.command`，或在项目目录运行：

Listing 2: 一键演示

```
1 python3 demo_runner.py
```

手动运行时，先启动 Receiver，再在另一个终端运行 Sender：

Listing 3: 手动运行

```
1 python3 receiver.py --host 127.0.0.1 --port 9001 --initial-seq 0
2 python3 sender.py --target-host 127.0.0.1 --target-port 9001 \
3   --packets 300 --cc-mode qlearning --window-size 1 \
4   --max-cwnd 64 --epsilon 0 --q-eval \
5   --qtable-file artifacts/models/active/q_table.json \
6   --metrics-file artifacts/metrics/metrics.csv \
7   --history-file artifacts/metrics/history.csv
```

训练应写入候选文件，再通过多种子筛选决定是否替换 active：

Listing 4: 训练与筛选

```
1 python3 train_q_learning.py --rounds 12 --packets 240 \
2   --q-table artifacts/models/candidates/q_table_training.json \
3   --q-alpha 0.001 --q-gamma 0.92 --q-epsilon 0.05 \
4   --rtt-trend-threshold-ratio 0.05
5
6 python3 screen_q_learning.py --include-aimd \
7   --candidate v9=artifacts/models/active/q_table.json \
8   --seeds 3,7,11,13,17,23,29,31 --packets 300 \
9   --case-timeout-s 45
```

生成对比图：

Listing 5: 绘图

```
1 python3 plot_metrics.py --metrics-file artifacts/metrics/metrics.csv \
2   --history-file artifacts/metrics/history.csv \
3   --output artifacts/plots/comparison.png \
4   --smooth-window 5
```

6 总结

本项目完成了题目五要求的 UDP 应用层可靠传输、虚拟瓶颈链路、AIMD 基线、Q-Learning 智能拥塞控制和实验可视化，并实现了动态带宽突变、快速重传与乱序处理、DQN 深度强化学习三项扩展。Q-Learning 始终保持 6 个状态和保持、加一、减半三个动作；通过修复动态 SRTT 控制周期的奖励偏差、采用固定 100ms 周期、比较状态动作策略、细化阈值搜索和 8 个随机种子公平筛选，最终 V9 在正常链路基本消除相对 AIMD 的吞吐差距，同时显著降低 RTT、重传和超时，并在带宽骤降场景提高吞吐。DQN 作为连续状态与细粒度动作扩展独立保留。